


RAG全栈技术实战指南

什么是RAG

◆ LLM=大脑, RAG=图书馆



什么是RAG

◆ RAG为LLM提供了认知以外的知识

大语言模型 (LLM) ----->

受限于训练预料，**缺乏**对领域知识和实时信息的认识

检索式增强生成 (RAG) ----->

为大语言模型提供回答问题所需要**的外部知识**，减少大模型的幻觉


好处 ----->

RAG所提供的知识**不需要改变 LLM本身**，只要把知识放在问题的上下文中，输入到LLM

什么是RAG

◆ RAG为LLM提供了认知以外的知识

Without RAG: LLM model has to be the only source of knowledge



什么是RAG

◆ RAG是除AI Agent以外最重要的LLM落地方向

AI搜索



搜索直接给出答案，将搜索到内容作为外部知识和问题一起输入到LLM（秘塔搜索/360搜索）

企业知识库



让LLM充分利用**企业内部知识**，为企业赋能（智能客服/智能业务助理/智能运维）


AI Agent



RAG本身也是Agent中的memory模块（**长期记忆**）

RAG是LLM最重要的落地场景

◆ RAG在学术圈




其中Survey
综述性的论文
就包含12篇

RAG是LLM最重要的落地场景

◆ RAG在学术圈


RAG不同的
范式



RAG是LLM最重要的落地场景

◆ RAG在学术圈


RAG最新趋势



RAG是LLM最重要的落地场景

◆ RAG在学术圈

Graph RAG



RAG是LLM最重要的落地场景

RAG主题占
据近20%

◆ RAG在企业圈

阿里巴巴通义实验室高级搜索算法专家
通义百炼RAG应用落地实践与挑战

智源研究院研究员
RAG 2.0: 记忆驱动的下一代检索增强系统

360人工智能研究院知识图谱及文档理解算法方向负责人
文档理解及知识图谱增强大模型应用实践

Diffy首席架构师
RAG 关键技术及未来趋势发展

澜舟科技合伙人、算法和应用VP
构建企业高价值场景的AI应用: RAG、数值计算与推理的技术实践

蚂蚁图计算开源负责人
Graph+AI: 立足DB-GPT社区探索GraphRAG未来架构

Percena创始人兼CEO
Graph+AI: 立足DB-GPT社区探索GraphRAG未来架构

JINA AI 联合创始人兼CTO
检索增强生成RAG 的实践、挑战与发展

资料摘自 [ML-Summit2024 全球机器学习技术大会](#)

RAG是LLM最重要的落地场景

◆ RAG在企业圈

RAG 落地应用与探索

本专题将深入探讨 RAG 的最新进展、成果和实践案例。我们将详细分析面向 RAG 的信息检索的创新方法，包括知识抽取、向量化、重排序、混合检索等在不同行业和场景下的微调和优化方法。



阿里云 AI 搜索 RAG 大模型优化实践

欧明栋 / 阿里云 高级算法专家

从 RAG 到微调：企业知识问答大模型演进之路



王元 / PayPal 高级 ML 科学家

马泽东 / PayPal 算法工程师



向量化与文档解析技术加速大模型RAG应用落地

覃扬 / 合合信息 智能创新事业部研发总监



下一代 RAG 引擎的技术挑战与实现

张颖峰 / 英飞流 CEO



Beyond Naive RAG

Pierre-Loic Doucet / Llamaindex 创始 AI 工程师

资料摘自Aicon全球人工智能开发与应用大会

RAG是LLM最重要的落地场景

◆ RAG在企业圈

制药




AI办公



家装



航空



资料摘自 2024世界人工智能大会

RAG是LLM最重要的落地场景

◆ RAG在开源圈



LangChain



LlamaIndex



RAGFlow



Anything



FastGPT



MaxKB



LangChain-ChatChat

RAG岗位需求

◆ RAG岗位需求

RAG算法技术专家【北京】 30-35k·16薪

经验不限 统招本科

猎头职位 某上海知名公司 新能源汽车 已上市 10000人以上

RAG工程师/Python专家-J738160【上海-闵行区】 30-55k

5-10年 本科

猎头职位 科技推广服务 1-49人

rag算法【上海】 30-60k·15薪

5-10年 统招本科

猎头职位 某北京大型计算机软件公司 计算机软件 10000人以上

RAG解决方案专家【广州-荔湾区】 35-55k·13薪

3年以上 本科

猎头职位 食品/饮料/酒水 5000-10000人

大模型算法工程师（RAG）【香港】 60-90k

经验不限 硕士

猎头职位 某上海大型银行公司 银行 不需要融资 5000-10000人

RAG算法工程师【北京-海淀区】 40-70k·16薪

5-10年 统招本科

猎头职位 通信设备 10000人以上

◆ RAG岗位需求



RAG岗位需求

◆ RAG岗位人才要求

1. 负责RAG系统的产品规划和功能设计，包括知识库管理、检索优化、推理逻辑等核心功能。
2. 制定产品路线图，确定技术方向和功能优先级。
3. 深度参与产品架构方案设计，确保RAG知识库在应用场景的性能和用户体验持续优化。
4. 收集并分析用户需求，提出改进建议，推动产品迭代。
5. 设计产品交互流程，优化用户界面，提升产品易用性。
6. 参与设计RAG知识库的重排算法、入库算法等全链路开发环节，从产品角度设计测试方法和评估方案。
7. 协调各部门资源，推进产品开发进度，确保项目按时交付。
8. 跟踪行业动态，研究竞品，确保产品保持市场竞争力。

课程内容和亮点

◆ RAG全栈技术实战指南

RAG技术细节

项目实战

项目软技能

课程内容和亮点

◆ RAG全栈技术实战指南

RAG技术细节

LLM大语言模型：基础token、transformer的知识、LLM训练过程，LLM技术演变、LLM涌现能力，如何为RAG挑选合适的LLM，以及不同的LLM调用方式

embedding模型：embedding特点和背后的技术架构，介绍主流embedding模型产品及其选型步骤、3种调用embedding方式和2种计算应用

Embedding数据库：详细介绍主流向量数据库chroma/milvus, 深入探讨索引技术IVF/HNSW/PQ

课程内容和亮点

◆ RAG全栈技术实战指南

RAG技术细节

文本解析和分块： 阐述下GIGO原则，多种文档格式文件解析（也包括RAGFlow中的deep-doc模块）以及文本分块技术（递归文本分块、语义分块）

RAG评估： RAG系统的关键；讲解评估的标准和自动评估框架ragas

14种检索增强： 6种查询增强，3种多索引增强，2种检索后增强：rerank重排和混合检索；以及模块增强：迭代增强生成和self-RAG自适应增强

课程内容和亮点

◆ RAG全栈技术实战指南

RAG技术细节


RAG+Graph：将知识图谱KG引入RAG，学习通过neo4j构建graphRAG

RAG+Agent：基于ReAct agent思路实现RAG路由，使得可以通过用户的问题自动选择合适的RAG系统来响应用户的请求

RAG+微调：介绍LLM微调和embedding微调相关的技术

课程内容和亮点

◆ 课程项目：企业员工组手



课程内容和亮点

◆ 课程项目：企业员工组手



课程内容和亮点

◆ 项目软技能

项目软技能

LLM需求能力分析：不同项目角色需要对AI大模型的了解程度差异性分析

企业应用开发要求：企业级应用的高可用性

转变思想：AI应用开发和传统软件开发的区别

课程内容和亮点

◆ 项目软技能

项目软技能

项目管理：企业里代码规范和代码管理

自我提升：如何自我学习，跟进前沿技术

AI岗位面试技巧：知识和框架

课程适合人群

◆ 适合人群

有一定的python基础 ----->

课程中代码是通过python来实现，需要了解一些简单的python基础，课程中用到相关的库也会在课程中做一些讲解

想转型到AI应用开发的开发者 ----->

可以从课程中学习到关于LLM、RAG、Agent、embedding、知识图谱等技术和实战，来提升AI应用开发能力，同时也了解AI应用开发过程的特殊性

抢先收获AI红利的开发者 ----->

LLM作为新质生产力，2024是AI应用的爆发年，而Agent、RAG是AI应用的主流落地方向

课程学习方式

◆ 课程学习方式

技术原理学习



学习RAG相关技术的底层逻辑

动手实践



AI应用开发最重要的就是躬身入局，理论+实践

答疑解惑



对学员学习过程中遇到的问题进行答疑解惑

讲师介绍

◆ 阿基米口

AI领域10年从业经验

机器学习+CV+LLM

AI模型训练和AI应用开发
实战项目经验

AI项目管理

infoQ写作社区、阿里
云开发者社区签约作者