

掌握未来AI趋势
RAG引领大语言模型新纪元

本章简介

◆ 大模型应用为什么需要 RAG

◆ 怎么学习RAG技术栈

◆ 解锁RAG三大核心

◆ RAG市场前景如何

◆ 大模型long context能力与RAG的争议

◆ 课程实战项目介绍

大模型应用遍地开花

- ◆ 大模型应用场景：查资料、写文案、会议总结、写代码、找bug、阅读论文、数据分析
- ◆ 国内大模型产品：文心一言、KIMI Chat、海螺AI、天工AI、秘塔搜索、360 AI搜索、秘塔写作猫
- ◆ 国外大模型产品：GPT4-O、Gemini、Claude、GitHub Copilot

大模型的两面性

- ◆ 擅长创意创造：文案生成，故事生成，文本润色无标准答案的创意类的任务，生成式AI都表现的非常出色
- ◆ 缺乏领域知识：受限于训练语料，甚至都不知道今天是几号



大模型的局限


- ◆ 缺乏企业专业知识：企业内部私有数据不公开；针对这部分数据的问题，大语言模型的输出没有得到任何**已知事实**的支持，输出的结果可信度低，存在**幻觉问题**
- ◆ 知识时效性：大模型知识更新难（**需要重新训练**）
- ◆ 结果不可解释性：大模型输出具有**随机性**，无法解释合理性

企业需求

- ◆ 企业业务需要有**内部私有数据**支撑
- ◆ 企业的业务知识会不断**变化和更新**
- ◆ 企业需要给客户准确的信息，内容**可追溯可解释**


大模型局限 vs 企业需求

◆ 如何有效的利用外部的企业数据：RAG（检索增强生成）



解锁RAG三大核心

◆ RAG=知识库+检索+大语言模型




解锁RAG三大核心

- ◆ **知识库**：囊括企业私有的数据，满足企业业务需求，可以根据需要进行**更新和维护**
- ◆ **检索**：根据用户的问题，在知识库中找到相关的信息，为回答提供丰富的上下文信息
- ◆ **大语言模型**：在丰富上下文加持下，大语言模型可以根据上下文信息来回答问题，减缓幻觉，降低生成错误信息的概率

大模型的long context vs RAG

◆ 大模型的long Context能力：支持百万级别token输入



Context windows are getting larger



大模型的long context vs RAG

- ◆ Kimi chat支持200万token输入

200万tokens




大模型的long context vs RAG

- ◆ 把企业知识作为长上下文直接输入到大语言模型，是否可行？
- ◆ 问题分析1：推理成本高，效率低
- ◆ 问题分析2：企业私有数据的安全风险高

大模型的long context vs RAG

- ◆ 问题分析3：大模型处理超长上下文的能力不完美，有待提升



大海捞针实验

在一个超长的上下文中的随机位置插入多个“针”（needles，即知识点）



验证大模型在超长上下文中能否精准的检索出这些“针”

大模型的long context vs RAG

◆ 问题分析3：大模型处理超长上下文的能力不完美，有待提升

Retrieval is not guaranteed, reasoning harder than retrieval

Asking GPT-4 to retrieve or retrieve & reason
1, 3, or 10 needles (facts) in a single turn
120,000 token context window



随着“针”的数量增加，LLM的检索与推理的正确率会下降

1K的上下文中，GPT4可以轻而易举的找到10个“针”

上下文扩大10倍甚至100倍后，很显然发生了大量的丢失（红色区域）

和针的位置有关：越在上下文末尾出现的“针”（比如编号6-10），越容易被检索到

RAG技术栈：从60分到90分的跨越


- ◆ 企业RAG面临的问题1：企业数据复杂多样（结构化、非结构化、格式多样），如何处理企业数据？
- ◆ 企业RAG面临的问题2：处理好的数据如何构建知识库（如何分块，如何高效索引）
- ◆ 企业RAG面临的问题3：用户问题的多样

RAG技术栈：从60分到90分的跨越

- ◆ 企业RAG面临的问题4：RAG中知识增强的关键是获得和问题相关的信息，如何高效的检索是关键？
- ◆ 企业RAG面临的问题5：如何处理多个上下文相关的信息（如何排序相关信息，如何写合适的prompt激发大模型潜能，哪种大模型合适）
- ◆ 企业RAG面临的问题6：如何评估RAG符合企业项目要求？

RAG技术栈：从60分到90分的跨越

- ◆ 面对企业RAG挑战，需要全面的RAG技术栈知识，找到不同项目最适合的技术



RAG人才炙手可热，你准备好了吗？

◆ 企业AI应用人才火热

大模型算法工程师 1.5-2.7万

ai 深度学习 文本分类 agent 知识抽取 函数调用 五险一金 补充医疗保险

 亚信科技（中国）有限公司 计算机软件 已上市 10000人以上  立即沟通

AI算法工程师 1.2-1.8万

linux 数学 计算机 机器学习 nlp 机器学习算法 Pytorch Python LLM

 苏州正载信息技术有限公司 计算机软件 民营 50-150人  立即沟通  简历处

大模型应用工程师 40-60万/年

gpt Gemini LLaMA LangChain 五险一金 补充医疗保险 补充公积金 年终奖

 上海东方龙新媒体有限公司 互联网/电子商务 国企 150-500人  立即沟通

岗位职责：

- 负责构建垂直行业的大语言模型，并能独立进行模型预训练、微调及模型验证等相关工作；
- 运用RAG及Agent智能体技术完成AI助手类应用开发；
- 设计并实现大模型在RAG、NLP等领域的创新应用方案，优化模型性能，提升业务效果；
- 根据需求完成相应的任务和数据预处理；
- 应对大模型部署和训练中的挑战，包括但不限于计算资源优化、分布式训练策略、模型压缩与加速等；
- 关注行业动态并持续跟踪前沿技术，积极学习新技术，不断提高自身能力。

职位信息

岗位职责：大模型应用的规划和开发，能完成垂类模型的灵活建设，支撑上层应用的AI场景。

任职要求：


- 能出差5-8个月。
- 大模型开发：至少精通一类大语言模型的部署和开发，精通一个Agent开发框架。
- 深度学习技能：对知识抽取和文本分类完成知识抽取、文本分类任务的训练。
- 模型微调：熟悉大模型的LoRA微调原理。
- RAG：掌握rag的基础流程，知道如何提升rag召回率。
- 函数调用、Agent使用：熟悉GPT-4、ChatGLM3模型执行函数调用，对大模型agent有一定的开发经验。

职位信息

工作职责：

- 参与WisGPT产品的研发与迭代，使WisGPT在架构上支持灵活切换到自研的RAG系统；
- 参与自研RAG系统的研发与迭代，基于开源项目进行自土化研发改造，使其具备行业创新、底层技术可控、研发投入有效特点；
- 进行上述两款产品的技术文档编写，主导推动对软件著作权申请、发明专利的申请工作；
- 关注AGI领域的实用性技术突破，参与后续AI产品线的技术分享与讨论，从技术创新与制定产品线Roadmap，确保公司在人工智能领域的技术领先型。
- 与团队合作，将AI技术应用于实际业务场景，提高产品的智能化水平。
- 参与AI产品的规划、执行和监控，确保项目按时、按质完成。
- 撰写相关的技术文档和报告，为团队提供技术支持和指导。
- 完成上级领导安排的其他工作。

◆ 企业AI应用开发行业分布



RAG人才炙手可热，你准备好了吗？

◆ 企业AI应用开发能力要求

1.参与过知识问答或对话式AI产品开发，构建大语言模型在RAG/Agent等方面的能力，包括数据体系、算法调优、提示工程、评估迭代；

2.构建体系化的专业性知识库，优化全链路的检索技术，并持续提升检索链路的准召；

3.通过RAG、SFT、RLHF等多项技术优化大语言模型在问答对话场景的业务效果；

2.熟悉RAG、Agent方向研发范式，了解RAG、Agent应用领域的先进技术和应用场景；

3.熟悉检索技术，包括向量检索、混合检索、重排序等；

2、基于langchain, llamaindex或者RAGflow的RAG类产品开发经验；

3、基于向量数据库相关产品的开发相关经验；

5、Embedding算法开发和调试经验；

熟练掌握LangChain/Llamaindex等LLM开发工具框架，有丰富的RAG和Prompt Engineering经验；熟悉NLP、ML和模型微调者优先。

本课程案例说明

- ◆ 企业员工组手：制度问答模块、基于知识图谱的企业知识问答模块【金融智库】
- ◆ 开发环境：python3.9、langchain、llamaindex、pytorch、transformers、gradio、fastapi、chroma、neo4j、jupyter

本课程案例说明

- ◆ 制度问答模块：是帮助员工更好的了解公司的制度，如考勤制度，报销制度等
- ◆ 数据：考勤管理和差旅费用标准（PDF、EXCEL）
- ◆ 目的：RAG整体流程和优化技术

本课程案例说明

- ◆ 金融智库：企业业务组手，基于知识图谱的企业知识问答模块，提供多方面的金融知识，给予金融员工分析和投资决策
- ◆ 数据：金融知识图谱数据（图数据库）
- ◆ 目的：将知识图谱引入RAG，提升RAG能力



本课程案例说明

◆ 总体架构图

