


RAG核心一

挑选符合企业的90分大语言基石模型

本章简介

- ◆ 大语言模型是RAG系统的重要组成部分，如何为RAG应用挑选合适的大语言模型是开发RAG应用的关键




本章简介

- ◆ 了解大模型技术和发展
- ◆ 国内外大模型产品
- ◆ 大模型的三种调用方式
- ◆ 如何分辨大模型的好坏
- ◆ 挑选大模型的4个步骤
- ◆ 加餐：你需要多大程度了解大模型？




什么是大语言模型

- ◆ 大语言模型是文字接龙，一个字一个字的逐个生成



什么是大语言模型

- ◆ 大语言模型是概率模型，预测所有字出现的概率，根据概率高低选择要生成的字



“语”的概率比其他的要高，于是下一个字就是输出“语”



模型输出具有**随机性**：非最高概率的字也有一定的机会输出


什么是大语言模型

- ◆ 所有字到底有多少？大语言模型把要预测的每一个字称为token，现在大语言模型都是按照token来计费的；所有的token称为vocab词表

GPT-3	----->	5万
Qwen2	----->	15万
LLaMA3.1	----->	12万

什么是大语言模型

- ◆ Token是如何生成的？生成token的方式称为分词（Tokenizer）




训练语料 -----> 拆分最细粒度（字母、字）

token <--- 统计词频 <--- 合并

什么是大语言模型

◆ BPE Tokenizer分词法 (从小到大合并)



什么是大语言模型

◆ GPT1的词表

{".": 1, ",": 2, "t": 3, "h": 4, "e": 5, "\"": 6, "o": 7, "a": 8

"bul": 2012, "um</w>": 2013, "ffe": 2014, "anyway</w>": 2015,

"by": 5329, "medical</w>": 5330, "pied</w>": 5331, "palace</w>"

<https://huggingface.co/openai-community/openai-gpt/raw/main/vocab.json>

什么是大语言模型

◆ 重新认识token

token



子词 un happy like ing a b c 笑 我们

语料中出现最频繁的部分



Token

为什么不能是单词



数量太大，语义重叠 like likes

Token

为什么不能是字符




毫无语义 a b c

什么是大语言模型

- ◆ 大语言模型背后的技术架构：transformer

Attention Is All You Need

Encoder
编码器
常用在
embedding模型



什么是大语言模型

◆ 理解transformer: self-Attention(multi-head-attention)


目的



理解词语的语义，生成好的语义特征

我要买一个苹果，我饿了

我要买一部苹果，现在的
安卓系统太卡了



相同的词在不同的上下文语境中含义是不一样的


每个词和其所在上下文的每个词有一定的联系，
这种联系可以很强相关，也可以是弱相关

什么是大语言模型

◆ 理解transformer: self-Attention(multi-head-attention)

在transformer用**self-attention自注意力机制**来建立每个token和其他所有token之间的相关性


self-attention自注意力机制: 能够很好的捕捉全局特征



It和animal关系最大
所以it指代animal, 而不是street

什么是大语言模型

◆ 大语言模型发展史：GPT（Generative Pre-Training）为例



什么是大语言模型

◆ 大语言模型是如何训练的？

从小学到大学学习了很多通用的知识

-----> **预训练阶段**

毕业工作，面对具体业务问题，不知所措

岗位培训（增强特定能力）

-----> **SFT：指令微调**

培训只会覆盖常见的工作项，真实业务复杂多变

分配一名导师，根据你的工作情况，给出指导反馈，做的好加强，做的不好的改正


-----> **RLHF：强化学习**

什么是大语言模型

◆ 大语言模型是如何训练的？

RW奖励模型：代表人类的意愿
判别生成结果的好坏


SFT指令微调
增强特定能力
(任务, 答案)



RLHF强化学习
每次生成通过奖励模型给出反馈
大模型通过这些反馈继续优化


什么是大语言模型

◆ 大语言模型的能力



国内外大模型产品必知必会

◆ 大模型产品生态



国内外大模型产品必知必会

◆ 国内外开源模型



阿里巴巴: 通义千问Qwen2(72B)



智谱清言: GLM4 (GLM4-9B)



deepseek: DeepSeekv2 (MOE)



百川: Baichuan2(13B)



面壁智能: CPM(CPM-bee 2B/10B miniCPM)



Meta: Llama 3.1(70B 405B)



Mixtral: Mixtral 8x7B Mixtral 8x22B (MOE)

国内外大模型产品必知必会

ANTHROPIC

Anthropic: Claude 3.5

◆ 国内外闭源模型



百度: 文心一言 (web/app/api)



Moonshot AI

月之暗面: Moonshot-v1(kimichat)



讯飞星火

讯飞: 星火大模型 (web/app/api)



minimax: abab 6.5 MOE (Glow智能体/海螺AI)




火山引擎

字节: 豆包(Coze/豆包)



昆仑万维: 天工



腾讯: 混元



openai: GPT4 GPT-4o (web/app/api) GPT-4o mini

Gemini

谷歌: gemini (ultra pro flash nano设备端)

没有GPU如何调用大模型？

◆ AI三大马车：算力优先

算法

数据

算力

没有GPU如何调用大模型？


◆ 大模型计算特点

大模型：大量的简单计算

- 乘法和加法
- 矩阵计算（乘法和加法）



需要GPU并行计算



CPU：复杂控制，计算核芯少（如8核）

GPU：简单控制，大量计算核芯

没有GPU如何调用大模型?

◆ 大模型文件

模型配置

 .gitattributes	1.52 kB	
 LICENSE	11.3 kB	
 README.md	4 kB	
 config.json	661 Bytes	
 generation_config.json	138 Bytes	
 merges.txt	1.67 MB	
 model.safetensors	988 MB 	
 tokenizer.json	7.03 MB	
 tokenizer_config.json	1.29 kB	
 vocab.json	2.78 MB	

参数文件

分词信息

词表

没有GPU如何调用大模型？

◆ 大模型推理过程

加载分词算法 -----> 加载模型参数 -----> 推理生成答案

没有GPU如何调用大模型?

◆ 通过GPU调用本地大模型

设置使用的GPU



```
import os
os.environ['CUDA_VISIBLE_DEVICES'] = '0'
```

加载分词器
tokenizer



```
tokenizer = AutoTokenizer.from_pretrained(model_path,
                                          trust_remote_code=True)
```

加载模型



```
model = AutoModel.from_pretrained(model_path,
                                   device_map="auto",
                                   trust_remote_code=True)
```

推理



```
model.chat(tokenizer,
            prompt ,
            history=[],
            temperature=0.1, top_p=0.8, top_k=20)
```

没有GPU如何调用大模型?

◆ 通过CPU调用大模型-ollama工具

背后框架
llama.cpp



支持
linux
windows
macos

Get up and running with large
language models.

支持
Qwen
LLaMA
...

支持
cpu
gpu

<https://ollama.com/>

<https://ollama.com/library>

没有GPU如何调用大模型?

◆ 通过CPU调用大模型-ollama工具

安装



[curl -fsSL https://ollama.com/install.sh | sh](https://ollama.com/install.sh)

使用



[ollama run qwen2:1.5b](#)

openai接口



```
from openai import OpenAI

client = OpenAI(
    base_url='http://localhost:11434/v1/',
    # required but ignored
    api_key='qwen2:1.5b',
)
chat_completion = client.chat.completions.create(
    messages=[
        {
            'role': 'user',
            'content': 'Say this is a test',
        }
    ],
    model='qwen2:1.5b',
)
print(chat_completion.choices[0].message.content)
```

没有GPU如何调用大模型?

◆ 通过AI厂商API调用大模型

注册



AI产商用户注册 <https://platform.deepseek.com/>

创建应用和key



接口调用



名称	Key	创建日期	最新使用日期	
	sk-4f510*****fd9d	2024-06-06	2024-08-14	 

创建 API key

```
from openai import OpenAI

client = OpenAI(api_key="<deepseek api key>", base_url="https://api.deepseek.com")

response = client.chat.completions.create(
    model="deepseek-chat",
    messages=[
        {"role": "system", "content": "You are a helpful assistant"},
        {"role": "user", "content": "Hello"},
    ],
    stream=False
)

print(response.choices[0].message.content)
```

没有GPU如何调用大模型?

◆ 通过AI厂商API调用大模型

API接口推荐 ----->

百度千帆: <https://cloud.baidu.com/doc/WENXINWORKSHOP/s/hlrk4akp7>

腾讯混元: <https://cloud.tencent.com/document/product/1729/97731>

通义千问: https://help.aliyun.com/document_detail/2712573.html

讯飞星火: <https://xinghuo.xfyun.cn/sparkapi>

字节豆包: <https://www.volcengine.com/docs/82379/1099320>

kimi: <https://platform.moonshot.cn/docs/pricing>

智谱AI: <https://open.bigmodel.cn/pricing>

deepseek: <https://platform.deepseek.com/api-docs/zh-cn/pricing/>

火眼金星：如何分辨大模型的好坏

◆ 模型大小对模型能力的影响：涌现能力

什么是涌现？




在较小的模型中不出现，而在较大的模型中出现的能力

涌现的2个表现



1.突破规模的临界点后，表现大幅度提升




火眼金星：如何分辨大模型的好坏

◆ 模型大小对模型能力的影响：涌现能力

涌现的2个表现



2.某些prompt策略对小模型失效，而对大模型起作用



涌现的直观启发



模型越大越好



简单的任务10B以下模型够用，复杂任务需要100B模型

火眼金星：如何分辨大模型的好坏

◆ 辨别模型好坏的关键：模型评测

评测步骤




1.维度：评测哪些能力

2.数据：在什么数据上评测

3.指标：如何判断评测结果好坏

火眼金星：如何分辨大模型的好坏

◆ 辨别模型好坏的关键：常见评测机构



MMLU

Massive Multitask Language Understanding

涵盖：STEM + 人文（humanities）+ 社会科学（social sciences）等57个学科，15908个问题

火眼金星：如何分辨大模型的好坏

◆ 辨别模型好坏的关键：常见评测机构

8 Key Capabilities · 29 Core Tasks · 100+ Evaluation Datasets

🔍 Language

📖 Knowledge

💡 Reasoning

💡 Creation

🔢 Math

🔗 Coding

📄 Long-Context

🤖 Agent

Core Tasks

Information Retrieval, Intention Recognition, Sentiment Analysis, Summarization, Critic, Translation, Traditional Cultural Understanding, Chinese Semantic Understanding, Multi-Turn Conversation

WIC

Word-in-Context, is a word sense disambiguation task cast as binary classification of sentence pairs. Given two text snippets and a polysemous word that appears in both sentences, the task is to determine whether the word is used with the same sense in both sentences.

CHID

ChID is a chinese idiom reading comprehension task, which requires to select the correct idiom to fill in the blank according to the context, with 10 candidate idioms.

[Go to CompassHub to view all benchmarks →](#)

[OpenCompass](#) 司南

火眼金星：如何分辨大模型的好坏

◆ 辨别模型好坏的关键：常见评测机构



评测指标

1. 准确性 (Accuracy)

Accuracy 指的是模型在所有评估实例中的平均正确性。正确性的概念在不同情况下可能有所区别，因而我们列举了评测工作中所考虑到的主要的准确性度量指标、这些度量指标的运用场景以及相关的正式定义。

1.1 Exact match

精确匹配是指：模型生成答案和正确的参考答案以字符串的形式完全匹配。在 HellaSwag, OpenBookQA, TruthfulQA, MMLU 等数据集上就是使用精确匹配作为默认的 Acc 度量指标。

1.2 Quasi-exact match

Quasi-exact 匹配的正确性条件在精确匹配的基础上进一步扩展，可以对模型生成答案进行一些细小的后处理（如大小写转化、删除空白和标点符号等）。BoolQ, IMDB, RAFT 等数据集上使用 Quasi-exact match 指标作为默认的 Acc 度量指标。

1.3 ROUGE-2

使用标准 ROUGE 分数 (Lin, 2004), 该分数考虑了 2-gram 重叠来确定正确性。这是 CNN/DailyMail 和 XSUM 的默认 Acc 指标。

1.4 正确率

在人工评测中，输入一个 prompt，模型回答正确记为 1，否则记为 0。正确率=回答正确的 prompt 个数/prompt 总个数。这是 CLCC 所使用的 Acc 度量指标。

2. Pass@k

对于代码生成模型的评测，模型针对每个单元测试问题生成 k ($k=1, 10, 100$) 个代码样本，如果有任何样本通过单元测试，则认为问题已解决，并报告问题解决的总比例，即 Pass@k 得分。

注：实际测试中，一般的做法是采样 $n=200$ 次，通过 c 次，用 $1-C(k, n-c)/C(k, n)$ 来降低评测值的方差。

flagEval

火眼金星：如何分辨大模型的好坏

◆ 辨别模型好坏的关键：常见评测机构

Compass Arena Leaderboard			Without Search	?	31 models 12202 votes 2024-09-12 update		
			Arena Elo	95% CI		Arena Elo	95% CI
1	GPT-4o-20240513	OpenAI	1091	+20/-17	6	ERNIE-4.0-8K-Preview-0518	1050 +25/-22
2	Qwen2-72B-Instruct	Alibaba	1083	+17/-18	7	Yi-Large	1047 +17/-19
3	Hunyuan-pro	Tencent	1071	+24/-24	8	DeepSeek-V2-Chat	1044 +25/-21
4	Qwen-Max-0428	Alibaba	1068	+16/-18	9	GPT-4-turbo-20240409	1043 +17/-20
5	Claude 3.5 Sonnet 20240620	Anthropic	1068	+28/-25	10	GLM-4-0520	1034 +23/-23

RAG应用：挑选大模型的四大步骤

◆ 在RAG应用中需要大模型的能力

信息抽取能力



大模型需要从RAG检索出来的上下文中，抽取出和问题最有价值的信息

上下文的阅读理解能力



大模型需要从RAG检索出来的上下文和问题进行语义理解，生成合适的答案

工具调用和function call能力



RAG应用中可能会调用外部工具和接口

RAG应用：挑选大模型的四大步骤

◆ 在RAG应用挑选大模型的四大步骤

模型大小选择



优先选择最大的模型进行测试是否可行，验证业务可行性
可行的情况下，收集数据可迁移到小模型

模型能力测试



构建业务的测试集，测试信息抽取能力、阅读理解能力和工具调用，function call能力

成本和设备



大模型的使用是有一定的成本，api调用成本和设备

企业数据安全



调用本地模型和外部api，要评估数据的安全

总结和展望

◆ 总结

什么是大语言模型



文字接龙：接龙的每个对象token

关键技术： transformer, 自注意力原理

训练步骤：预训练+指令微调+基于人类反馈的强化学习

如何使用大语言模型



GPU: transformers

CPU: ollama

API: 直接访问产商http服务

总结和展望

◆ 总结

如何评价大语言模型



涌现能力：模型越大越好

模型评测：评测能力+评测数据+评测指标

如何挑选大语言模型



模型大小选择

模型能力测试

成本和设备

数据安全

总结和展望

◆ 展望：项目角色和大模型的关系

产品经理

职责：做什么（功能, 交互设计），为什么做（用户痛点需求，市场前景，成本收益）

大模型能力要求

- 大模型基础知识了解：什么是大模型 / 基本概念如训练 微调 学习等 --> 方便和工程师沟通
- 大模型能力的边界了解：有哪些能力 / 可以做什么 / 有什么缺点 --> 方便结合公司业务找到切入点
- 大模型基本使用（prompt）：更体会大模型的能力和测试
- 业务数据从哪里来？：评估功能是否有数据来支持实现以及最终验收评估

总结和展望

◆ 展望：项目角色和大模型的关系

大模型应用开发工程师

职责：怎么做（如何实现）

大模型能力要求

- 大模型基础知识：大模型技术架构 (transformer, embedding) / 哪些可用的大模型
- 如何调用大模型: gpu知识 / 复杂prompt技术 / python / pytorch / transformers
- 大模型能力评估：是否需要微调
- 大模型应用开发中间件: langchain / llamaindex / rag / agent / embedding / 向量数据库等
- 大模型技术选型：根据业务选择什么大模型 / 中间件选型)
- 大模型AI应用开发流程: 开发 / 迭代 / 评估
- 功能容错能力分析：是否允许出现错误 / 如何后处理

总结和展望

◆ 展望：项目角色和大模型的关系

大模型推理部署工程师

职责：大模型部署 稳定/高效

大模型能力要求

- 推理框架：vLLM、Tensorrt-LLM、DeepSpeed 和Text Generation Inference
- 掌握推理优化技术：模型压缩/量化技术、解码方法、底层优化与分布式并行推理
- GPU优化知识：cuda / 并行计算优化 / 访存优化 / 低比特计算
- 主流大模型架构：包含哪些算子 / 各部分耗时分析和优化
- 模型推理性能测试：并发性能，资源利用率，吞吐

总结和展望

◆ 展望：项目角色和大模型的关系

大模型算法工程师

职责：训练和微调自研的本地垂类大模型

大模型能力要求

- 推理熟悉大模型的训练和微调全过程：数据准备，清理，预训练、指令微调、强化学习，分布式训练，训练策略，模型评测
- 参数高效模型训练技术：LoRA / Prompt Tuning / Prefix Tuning / P-Tuning
- 大模型训练框架：Pytorch、Tensorflow、Megatron、Deepspeed
- 负责跟踪、探索业界前沿的大模型训练及优化方案
- 大模型评测