


RAG核心二

挑选合适RAG的向量Embedding模型

本章简介

- ◆ embedding模型是RAG系统的重要组成，如何为RAG应用挑选合适的embedding模型也是开发RAG应用的关键



本章简介

◆ 了解embedding模型的重要性

◆ embedding是如何炼成的

◆ 了解主流中文embedding模型


◆ 如何挑选embedding模型

◆ 实战



embedding模型的重要性


◆ 什么是embedding




embedding是将数据对象（如文本）映射到固定大小的连续一维数字数组（向量空间）的技术。向量空间通常具有几百到几千的维度，每个维度代表某个语义特征或属性

embedding模型的重要性


◆ 什么是embedding




Male-Female



Verb Tense




Country-Capital



在embedding向量空间中，语义相似的实体在向量空间中映射得更近，而不相似的实体映射得更远，这也是向量模型需要学习的目标

embedding模型的重要性

◆ embedding在RAG中的作用



Embedding的好坏关系到上下文的相关性，如果引入不相关的上下文会对LLM回答问题造成干扰


RAG需要在外部知识库中检索和问题相关的文档，来增加问题的上下文信息。而判断相关性就是通过问题的embedding和文档的embedding来判断的

embedding是如何炼成的?

◆ embedding背后的模型: BERT

BERT ----> Transformer中的encoder部分


预测下一句
学习句子间语义
的关联性



Pre-training

完形填空
学习词语在不同
上下文的语义

Encoder
编码器




embedding是如何炼成的?

◆ embedding背后的模型: BERT (完形填空)

训练文本 -----> 机器学习

模型输入 -----> [CLS] 机 [MASK] 学习

模型预测 -----> 器的概率



完形填空
学习词语在不同上下文中的语义

embedding是如何炼成的？

◆ embedding背后的模型：BERT（预测下一句）


训练文本 -----> 今天天气如何？ 很好
今天天气如何？ 那辆车不错

模型输入 -----> [CLS] 今天天气如何？ [SEP] 很好

模型预测 -----> YES

模型输入 -----> [CLS] 今天天气如何？ [SEP] 那辆车不错


模型预测 -----> NO



预测下一句
学习句子间语义的关联性

主流中文embedding模型

◆ MTEB榜单 (Massive Text Embedding Benchmark)



Overall Bitext Mining Classification Clustering Pair Classification Reranking **Retrieval** STS Summarization Retrieval w/Instructions

Retrieval is the task of finding relevant documents for a query.

English **Chinese** French Law LongEmbed Polish Russian RAR-b BRIGHT

信息检索任务

Retrieval Chinese leaderboard 🇨🇳


- Metric: Normalized Discounted Cumulative Gain @ 10 (nDCG@10)
- Languages: Chinese
- Credits: [FlagEmbedding](#)

Rank	Model	Model Size (Million Parameters)	Memory Usage (GB, fp32)	Average	CmedqaRetrieval	CovidRetrieval	DuRetrieval	Ecor
1	Zhihui_LLM_Embedding	7069	26.33	76.74	48.69	84.39	91.34	71.9
2	xiaobu-embedding-v2	326	1.21	76.5	47.14	89.4	89.44	70.5
3	zpoint_large_embedding_zh	326	1.21	76.36	47.16	89.14	89.23	70.7
4	gte-Qwen2-7B-instruct	7613	28.36	76.03	48.69	83.65	87.44	71.1

MTEB提供不同embedding任务的多种基准评测数据集

主流中文embedding模型

◆ BERT架构-阿里的GTE系列




Task Type	Text Pair Format	Query	Doc
Web Page	(title, body)	Providence Real Estate Providence Homes for Sale	Founded by Roger Williams in 1636, Providence is recognized as one of the country's oldest cities. ...
Academic Paper	(title, abstract)	Polymer Quantum Mechanics and its Continuum Limit	A rather non-standard quantum representation of the canonical commutation relations of quantum mechanics. ...
Hyperlink	(citation, reference)	After the championship in 1996, the PGA of America raised its stake to 50% and announced that ...	Pebble Beach Golf Links The largest margin of victory ever in a major championship, surpassing the 13-shot ...
Social Media	(post, comment)	Pretty sure any team with LeBron James will be a playoff contender. Considering UNC would be in the East. ...	I was being sarcastic and making fun of the East, but honestly I was really in deep thought about this ...
Knowledge Base	(entity, description)	Animation	Animation is the process of creating the illusion of motion and shape change by means of the rapid display of ...
Community QA	(question, answer)	How the human species evolved?	A tough question as it overlaps science and theology. Since you asked "how the human species evolved?" I'll assume ...
News	(summary, content)	Nepalese Opposition Welcomes Return of Parliament	Nepal's opposition alliance formally calls off weeks of pro-democracy protests after King Gyanendra reinstates ...
Code	(text, code)	SetMaxRecords sets the MaxRecords field's value.	func (s *DescribeSnapshotCopyGrantsInput) SetMaxRecords(v int64) *DescribeSnapshotCopyGrantsInput { s.MaxRecords

- 1.生成相关的句子对A和B，两个句子输入bert
- 2.对所有的 token对应的向量求均值得到对应句子embedding
- 3.对两个embedding计算cos相似度进行学习

主流中文embedding模型

◆ BERT架构-阿里的GTE系列




在有标签数据进行微调学习

1.构造三元组 (q,a,i) 其中q和a相关, q和i不相关

2.学习目标: q和a的embedding距离尽可能小, q和i的embedding距离尽可能大


主流中文embedding模型

◆ BERT架构-BAAI的BGE系列



主流中文embedding模型

◆ BERT架构-BAAI的BGE系列



如何挑选embedding模型

◆ MTEB基准测试榜单是一个好的开始

Overall

Bitext Mining

Classification

Clustering

Pair Classification

Reranking

Retrieval

STS

Summarization

Retrieval w/Instructions

English

Chinese

French

Polish

Russian

Overall MTEB Chinese leaderboard (C-MTEB) 🇨🇳

Metric: Various, refer to task tabs

Languages: Chinese

Credits: [FlagEmbedding](#)

Rank	Model	Model Size (Million Parameters)	Memory Usage (GB, fp32)	Embedding Dimensions	Max Tokens	Average (35 datasets)	Classification Average (9 datasets)	Clustering Average (4 datasets)	PairClassification Average (2 datasets)	Reranking Average (4 datasets)
1	xiaobu-embedding-v2	326	1.21	1792	512	72.43	74.67	65.17	91.87	72.58
2	gte-Qwen2-7B-instruct	7613	28.36	3584	131072	72.05	75.09	66.06	87.48	68.9%
3	zpoint_large_embedding_zh	326	1.21	1792	512	71.88	74.43	62.23	91.55	72.3%
4	IYun-large-zh					71.04	74.18	66.35	90.87	69.3%
5	piccolo-large-zh-v2					70.95	74.59	62.17	90.24	70%
6	AGE_Hybrid					70.85	74.14	66.64	87.08	68.7%

如何挑选embedding模型

◆ 关注维度

任务	----->	MTEB提供如classification, clustering, retrieval, summarization等不同任务的评测，RAG重在检索信息，可以选择retrieval
语言支持	----->	中文，英文，多语言
评测分数	----->	排名和分数
模型大小和内存使用	----->	取决于设备资源和执行性能（延迟）
embedding维度	----->	输出embedding向量的长度，长度长可以捕捉更复杂的语义，长度小执行性能更好，更易于存储，一般不需要太长
最大tokens数	----->	embedding模型支持输入的token数，注意超过会被截断，影响RAG的文本分割

如何挑选embedding模型

◆ 筛选方法论

MTEB评测并不总是可靠的



MTEB的评测集公开的，
可能有些水分，参考发布
模型机构

关注维度



选择模型



baseline model



评测结果



构建自己的数据集



总结

◆ 总结

embedding的重要性



越相同语义的embedding在向量空间中距离越接近

embedding模型能为大模型提供问题语义相近的上下文

总结

◆ 总结

Embedding是如何练成的?

基于BERT架构：完形填空/下一句预测来捕捉词语的语义特征

GTE/BGE: 在BERT基础上，增加对比学习和度量学习，性能更好

挑选embedding模型

重要参考：MTEB

选择基线模型，在自建数据集上迭代评测