


**有效评估RAG
是提升RAG的关键**

本章简介

- ◆ RAG系统构建完成之后，如何判断是否达到预期效果？RAG的评估至关重要，不仅是项目好坏的标准，也是指出项目提升的方向



评价rag系统 好与坏

本章简介

◆ RAG评估标准

◆ 实战




◆ RAG评估的三大步骤

◆ RAG评估框架：ragas

RAG评估标准

◆ 简化RAG流程



通过衡量这三者之间的相关程度来评估 RAG 的效果的好坏

RAG评估标准

◆ RAG评估标准



RAG评估标准

◆ RAG评估标准

Faithfulness
(忠实性)



Context: 苹果公司由史蒂夫·乔布斯和史蒂夫·沃兹尼亚克于1976年创立

Answer: 苹果公司成立于1976年

Answer Relevance
(答案相关性)



query: 苹果公司是什么时候成立的?

Answer1: 苹果公司成立于1976年

Answer2: 苹果公司是一家科技公司

Context Relevance
(上下文相关性)



query: 苹果公司是什么时候成立的?

Context1: 苹果公司由史蒂夫·乔布斯和史蒂夫·沃兹尼亚克于1976年创立

Context2: 苹果公司发布了iPhone

RAG评估的三大步骤

◆ RAG评估三大步骤

构建
评估数据集

评估指标

执行评估



RAG评估框架:ragas

◆ ragas特点



Ragas



最早是**无参考**的评估框架（RAG评估过程，不必依赖人工标注的**标准答案**）

利用的是大语言模型的能力来判断生成答案和问题以及上下文的相关性

RAG评估框架:ragas

◆ ragas评估指标



RAG评估框架:ragas

◆ ragas数据集格式

```
from datasets import Dataset
from ragas.metrics import context_recall
from ragas import evaluate

data_samples = {
    'question': ['When was the first super bowl?', 'Who won the most super bowls?'],
    'answer': ['The first superbowl was held on Jan 15, 1967', 'The most super bowls have been won by The'],
    'contexts': [['The First AFL-NFL World Championship Game was an American football game played on Janu',
                  'The Green Bay Packers...Green Bay, Wisconsin.', 'The Packers compete...Football Conference']],
    'ground_truth': ['The first superbowl was held on January 15, 1967', 'The New England Patriots have wo']
}

dataset = Dataset.from_dict(data_samples)
score = evaluate(dataset, metrics=[context_recall])
score.to_pandas()
```

问题
答案
上下文
人工标
准答案

question/answer/contexts/ground_truth

RAG评估框架:ragas

◆ ragas评估指标: Faithfulness

question/answer/contexts

生成的答案answer拆分为单独的陈述

对每个陈述, 验证是否可以从给定的上下文中推断出它

统计能够从上下文推断出来的陈述的比例

RAG评估框架:ragas

◆ ragas评估指标: Faithfulness

问题

问题: 爱因斯坦出生于何时何地?

上下文

背景: 阿尔伯特·爱因斯坦 (Albert Einstein, 生于 1879 年 3 月 14 日) 是一位出生于德国的理论物理学家, 被广泛认为是有史以来最伟大、最有影响力的科学家之一

生成的
答案

高度忠实的答案: 爱因斯坦于 1879 年 3 月 14 日出生于德国。

低忠实度答案: 爱因斯坦于 1879 年 3 月 20 日出生于德国。

步骤1: 将生成的答案拆分为单独的语句。

• 语句:

• 陈述 1: “爱因斯坦出生在德国。”

• 陈述 2: “爱因斯坦出生于 1879 年 3 月 20 日。”

步骤2: 对于每个生成的语句, 验证是否可以从给定的上下文中推断出它。

• 声明 1: 是的

• 声明 2: 否

$$\text{Faithfulness} = \frac{1}{2} = 0.5$$

RAG评估框架:ragas

◆ ragas评估指标: Faithfulness-拆分提示词写法

给定一个问题、一个答案以及答案中的句子，分析每个句子在“句子”下的复杂性，并将每个句子分解成一个或多个完全可理解的陈述，同时确保每个陈述中不使用代词。将输出格式化为JSON。

- 问题: “阿尔伯特·爱因斯坦是谁，他最出名的是什么?”
- 答案: “他是一位出生于德国的理论物理学家，被广泛认为是有史以来最伟大的物理学家之一，也是最有影响力的物理学家之一。他因发展相对论而最为人所知，他还对量子力学理论的发展做出了重要贡献。”
- 句子:
 - 0: 他是一位出生于德国的理论物理学家，被广泛认为是有史以来最伟大的物理学家之一，也是最有影响力的物理学家之一。
 - 1: 他因发展相对论而最为人所知，他还对量子力学理论的发展做出了重要贡献。
- 分析:
 - {"sentence_index": 0, "simpler_statements": ["阿尔伯特·爱因斯坦是一位出生于德国的理论物理学家。", "阿尔伯特·爱因斯坦被认为是有史以来最伟大的物理学家之一，也是最有影响力的物理学家之一。"]},
 - {"sentence_index": 1, "simpler_statements": ["阿尔伯特·爱因斯坦因发展相对论而最为人所知。", "阿尔伯特·爱因斯坦还对量子力学理论的发展做出了重要贡献。"]}

RAG评估框架:ragas

◆ ragas评估指标: Faithfulness-推断提示词写法

你的任务是根据给定的上下文来判断一系列陈述的忠实度。对于每个陈述，如果陈述可以根据上下文直接推断出来，则返回裁决为1；如果陈述不能根据上下文直接推断出来，则返回裁决为0。

- 上下文: “约翰是XYZ大学的学生。他正在攻读计算机科学学位。这个学期他注册了几门课程，包括数据结构、算法和数据库管理。约翰是一个勤奋的学生，花费大量时间学习和完成作业。他经常在图书馆待到很晚来完成他的项目。”

- 陈述: ["约翰主修生物学。", "约翰是一个专注的学生。"]

- 答案:

- {"statement": "约翰主修生物学。", "reason": "约翰的专业明确提到是计算机科学。没有信息表明他主修生物学。", "verdict": 0},
- {"statement": "约翰是一个专注的学生。", "reason": "上下文说明他花费大量时间学习和完成作业。此外，提到他经常在图书馆待到很晚来完成他的项目，这暗示了他的专注。", "verdict": 1},

RAG评估框架:ragas

◆ ragas评估指标: Answer Relevance

question/answer



生成的答案answer生成多个潜在的问题



计算每个潜在问题和原始问题的embedding语义相似度



所有相似度的取平均

RAG评估框架:ragas

◆ ragas评估指标: Answer Relevance

问题
←
生成的
答案
←

问题: 法国在哪里, 首都是什么?

低相关性答案: 法国位于西欧。

高相关性答案: 法国位于西欧, 巴黎是其首都。

步骤1: 使用大型语言模型 (LLM) 对生成的答案中问题的 'n' 变体进行逆向工程。例如, 对于第一个答案, LLM 可能会生成以下可能的问题:

- 问题 1: “法国位于欧洲的哪个地区?”
- 问题 2: “法国在欧洲的地理位置是什么?”
- 问题 3: “您能确定法国所在的欧洲地区吗?”

步骤2: 计算生成的问题与实际问题之间的平均余弦相似度。

RAG评估框架:ragas

◆ ragas评估指标: Answer Relevance生成问题提示词

描述 ←

为给定的答案生成一个问题，并确定答案是否含糊其辞。如果答案是含糊其辞的，则给出1；如果答案是明确的，则给出0。含糊其辞的答案是那种回避、模糊或不明确的。例如，“我不知道”或“我不确定”就是含糊其辞的答案。

例子 ←

- "答案": "阿尔伯特·爱因斯坦出生于德国。"
- "上下文": "阿尔伯特·爱因斯坦是一位出生于德国的理论物理学家，被广泛认为是有史以来最伟大的、最有影响力的科学家之一。"
- "输出":
 - "问题": "阿尔伯特·爱因斯坦在哪里出生？",
 - "是否含糊其辞": 0,  只选择明确的答案

RAG评估框架:ragas

- ◆ ragas评估指标: Context Recall

groud_truth/contexts

人工标准答案groud_truth拆分为单独的陈述

对每个陈述, 验证是否可以从给定的上下文中推断出它

统计能够从上下文推断出来的陈述的比例

RAG评估框架:ragas

◆ ragas评估指标-Context Recall

问题：法国在哪里，首都是什么？

人工标准答案

基本事实：法国位于西欧，首都是巴黎。

法国位于西欧，包括中世纪城市、高山村庄和地中海海滩。首都巴黎以其时装屋、包括卢浮宫在内的古典艺术博物馆和埃菲尔铁塔等古迹而闻名。

上下文

法国位于西欧，包括中世纪城市、高山村庄和地中海海滩。该国还以其葡萄酒和精致的美食而闻名。拉斯科的古老洞穴壁画、里昂的罗马剧院和宏伟的凡尔赛宫证明了其丰富的历史。

步骤1：将 ground truth 答案分解为单独的陈述。

• 语句：

• 声明 1：“法国在西欧。”

• 陈述 2：“它的首都是巴黎。”

步骤2：对于每个 ground truth 语句，验证它是否可以归因于检索到的上下文。

• 声明 1：是的

• 声明 2：否

$$\text{Context Recall} = \frac{1}{2} = 0.5$$

RAG评估框架:ragas

◆ ragas评估指标: Context Recall推断提示词

描述 ←

给定一个上下文和一个答案,分析答案中的每个句子,并分类判断该句子是否可以归因于给定的上下文。仅使用"Yes" (1) 或"No" (0) 作为二元分类。输出包含理由的JSON。

例子 ←

- "问题": "你能告诉我关于阿尔伯特·爱因斯坦的什么信息?"
- "上下文": "阿尔伯特·爱因斯坦 (1879年3月14日 - 1955年4月18日) 是一位出生于德国的理论物理学家, 被广泛认为是有史以来最伟大的、最有影响力的科学家之一。他以发展相对论而闻名, 同时也对量子力学做出了重要贡献, 因此是现代物理学在二十世纪初几十年内对自然科学理解的革命性重塑中的中心人物。"
- "答案": "阿尔伯特·爱因斯坦, 出生于1879年3月14日, 是一位出生于德国的理论物理学家, 被广泛认为是有史以来最伟大的、最有影响力的科学家之一。他因对理论物理学的贡献而获得1921年诺贝尔物理学奖。他在1905年发表了4篇论文。爱因斯坦于1895年移居瑞士。"
- "分类":
 - "陈述": "阿尔伯特·爱因斯坦, 出生于1879年3月14日, 是一位出生于德国的理论物理学家, 被广泛认为是有史以来最伟大的、最有影响力的科学家之一。"; "理由": "上下文中清楚地提到了爱因斯坦的出生日期。"; "结果": 1,
 - "陈述": "他在1905年发表了4篇论文。"; "理由": "给定的上下文中没有提到他写的论文。"; "结果": 0,

RAG评估框架:ragas

- ◆ ragas评估指标: context precision (从排序角度考察检索)

question/groud_truth/contexts

对于topk的每个上下文: 给定问题, 判断是否可以从上下文中得出标准答案, 1为是, 0为否

考虑上下文排序权重: 前面k个相关的比率

加权平均

RAG评估框架:ragas

- ◆ ragas评估指标: context precision (从排序角度考察检索)

检索得到Top3: context

判断能否得出标准答案: [0, 1, 1]

Top3 累加权重: $[0/1, (0+1)/2, (0+1+1)/3]$

加权: $(0*0+1*1/2, 1*2/3) / (0+1+1)$

Context Precision = $1.16/2 = 0.58$

RAG评估框架:ragas

◆ ragas评估指标: context precision推断提示词

描述 ←

给定问题、答案和上下文，验证上下文是否有助于得出给定的答案。如果有帮助则给出裁决为"1"，如果没有帮助则为"0"，以JSON输出。

例子 ←

- "问题": "你能告诉我关于阿尔伯特·爱因斯坦的什么信息?"
- "上下文": "阿尔伯特·爱因斯坦 (1879年3月14日 - 1955年4月18日) 是一位出生于德国的理论物理学家，被广泛认为是有史以来最伟大的、最有影响力的科学家之一。他以发展相对论而闻名，同时也对量子力学做出了重要贡献，因此是现代物理学在二十世纪初几十年内对自然科学理解的革命性重塑中的中心人物。"
- "答案": "阿尔伯特·爱因斯坦，出生于1879年3月14日，是一位出生于德国的理论物理学家，被广泛认为是有史以来最伟大的、最有影响力的科学家之一。他因对理论物理学的贡献而获得1921年诺贝尔物理学奖。他在1905年发表了4篇论文。爱因斯坦于1895年移居瑞士。"
- "验证":
 - reason="提供的上下文确实有助于得出给定的答案。上下文包括了关于阿尔伯特·爱因斯坦的生活和贡献的关键信息，这些都在答案中得到了反映。",
 - 裁决: 1

RAG评估框架:ragas

◆ ragas评估过程

```
from datasets import Dataset
import os
from ragas import evaluate
from ragas.metrics import faithfulness, answer_correctness
```

```
os.environ["OPENAI_API_KEY"] = "your-openai-key"
```

```
data_samples = {
    'question': ['When was the first super bowl?', 'Who won the most super bowls?'],
    'answer': ['The first superbowl was held on Jan 15, 1967', 'The most super bowls have been won b'],
    'contexts' : [['The First AFL-NFL World Championship Game was an American football game played o'],
    ['The Green Bay Packers...Green Bay, Wisconsin.', 'The Packers compete...Football Conference']],
    'ground_truth': ['The first superbowl was held on January 15, 1967', 'The New England Patriots h']
}
```

构建数据集 ←

```
dataset = Dataset.from_dict(data_samples)
```

```
score = evaluate(dataset,metrics=[faithfulness,answer_correctness])
score.to_pandas()
```

执行评估 ←

→ 评估指标

执行RAG评估后

◆ 执行评估后要做什么

分析评估不好的BAD CASE

RAG评估后行动项

提出解决方案：如改进检索方式、替换embedding模型、改写生成答案的提示词等

重新评估验证解决方案是否有效

总结

◆ 总结

RAG评估

目的：问题 / 上下文 / 生成答案之间的相关性

步骤：构建评估数据集、选择评估指标、执行评估

框架：无参考和有参考结合的评估方法ragas（结合llm能力）

总结

◆ 总结

评估指标	目的	计算方法
忠诚度 (Faithfulness)	衡量生成答案与给定上下文事实之间的一致性	验证生成答案是否能够从上下文中推断出来
答案相关性 (Answer Relevancy)	重点衡量生成答案与用户提问的匹配程度	做逆向工程，比较从生成答案的潜在问题与原始问题的相似度

总结

◆ 总结

评估指标	目的	计算方法
上下文召回率 (Context Recall)	关注于模型在检索过程中能否准确地找到与问题相关的上下文信息	分析标准答案中的句子是否可以从检索到的上下文中推断出来
上下文精度 (Context Precision)	重点判断与标准答案的所有相关的上下文是否都排在最前面	从排序角度考察检索到上下文的有效性，越相关的上下如果排序越前面检索性能越好