


从RAG到Graph RAG 让企业知识图谱更智能

本章简介

- ◆ **知识图谱** (Knowledge Graph) 是一种大规模的图结构数据库，用于存储和表示**实体** (如人、地点、事物、概念等)、**属性** (如名称、类型、描述等) 以及这些实体之间的**关系**
- ◆ **知识图谱**旨在将现实世界中的信息以结构化的方式组织起来，使得机器可以更加高效地理解 and 处理这些信息


本章简介

- ◆ 知识图谱 (Knowledge Graph) 中存储了丰富的语义相关数据，如何将知识图谱引入RAG系统中提升RAG性能是一个有意义的工作？



本章简介

- ◆ 认识金融智库知识图谱
数据：特别的知识三元组
- ◆ 如何存储和操作知识图谱：neo4j和nebulagraph
- ◆ 动手构建金融智库知识图谱
- ◆ RAG和Graph RAG有什么区别？
- ◆ 构建金融智库Graph RAG
- ◆ 总结和展望：如何自我学习，跟进前沿技术




认识知识图谱

◆ 什么是知识图谱

概念：知识图谱 (Knowledge Graph) 是用来表示实体及其关系的结构化图形

组成部分：三元组 <主体, 谓语, 客体>



认识知识图谱

◆ 什么是知识图谱：三元组

主体 (Subject)：指的是要描述的实体或对象。在知识图谱中，主体通常是某个具体的节点，代表一个实体，比如某个人、地点或事物

谓语 (Predicate)：指的是主体和客体之间的关系或属性。谓语通常是一个动词或动词短语，描述了主体与客体之间的连接方式

客体 (Object)：指的是与主体相关联的另一个实体或一个具体的属性值。客体可以是另一个实体（节点）或者是一个字面量（literal），如字符串、数字等

认识知识图谱


◆ 什么是知识图谱：三元组



实体之间的关系是无方向
相互认识

认识知识图谱

◆ 什么是知识图谱：三元组



实体之间的关系是有方向

认识知识图谱

◆ 什么是知识图谱：主要特点

**图形结构化
数据表示**

节点代表实体，
边代表实体之间的
关系。这使得
信息在语义层面
上更具关联性

语义丰富性

明确的关系类型和
属性来描述不同实
体之间的连接。有
助于更深层次的理解和推理

**支持推理和
推断**

能够从已知信息中
推断出新的事实。
例如，通过关系链
的传递性或对称性
来推断新的关联

认识知识图谱

◆ 什么是知识图谱：应用案例

医疗诊断

应用场景：通过知识图谱整合患者的症状、体征、病史和医学知识库，进行疾病推断和诊断

输入：患者报告的症状，如发烧、咳嗽、呼吸困难

图谱数据：将这些症状与疾病节点连接，图谱中有疾病与症状的关联，例如，图中可能有信息显示“流感”与“发烧”、“咳嗽”相关

推断：通过推理引擎，结合症状与疾病的关联，可能推断出最可能的疾病，如流感或肺炎

认识知识图谱

◆ 什么是知识图谱：应用案例

推荐系统

应用场景：在电商平台上，利用知识图谱进行商品推荐

输入：用户的浏览历史、购买记录

图谱数据：商品之间的关系，用户的兴趣图谱。例如，用户A购买过的商品X与商品Y在图谱中有“经常一起购买”的关系

推断：结合用户的过去行为和商品关系，推断用户可能还对商品Y感兴趣，从而进行推荐

认识知识图谱

◆ 什么是知识图谱：应用案例

问答系统

应用场景：能问答系统，基于知识图谱回答用户的问题

输入：用户问题，如“爱因斯坦在哪一年出生？”

图谱数据：包含人物、生平事件、时间等节点。例如，爱因斯坦节点与“出生年份”属性的值是1879。

推断：通过查询知识图谱，找到爱因斯坦节点，并提取“出生年份”属性，返回答案“1879”

认识知识图谱

◆ 什么是知识图谱：金融知识图谱数据

金融智库

知识图谱数据：金融实体的风险事件数据、企业投资数据

目的：快速收集企业之间的投资关系和风险事件，辅助金融决策和金融投研业务

认识知识图谱

◆ 什么是知识图谱：金融知识图谱数据

风险事件
数据



数据：事件描述了金融实体在市场行为、财报信息、公司运营、信用评估、公司声誉出现的一些问题，比如哪个企业发生了债务危机，裁员了等等，这些都是企业面临危机的信号。这些事件来自各大主流财经类资讯平台、传统媒体、新媒体的报导

认识知识图谱

◆ 什么是知识图谱：金融知识图谱数据

```
{ 'title': '雪佛龙计划大规模裁员 约6000个工作岗位面临风险',  
  'content': '北京时间28日消息，雪佛龙计划今年将全球员工人数削减10%至15%，这是  
在新冠肺炎之后全球石油巨头中最大规模的裁员。此番裁员相当于该公司45,000名非加油  
站员工中的约6,000人，并可能是BP和壳牌等大型石油公司裁员的先兆。截至目前，裁员  
主要集中在油田服务领域和北美的独立生产商之中。雪佛龙“正在简化我们的组织结构，以  
反映出效率并与预期的活动水平保持一致，”该公司周三在一份公告中说。“这是一个艰难  
的决定，我们不会轻易做出这样的决定。”',
```

```
  'label': [{ 'event_type': '裁员',  
               'arguments': [{ '主体': '雪佛龙'}, { '时间': '北京时间28日' }] } ] }
```

来源：openkg的IREE：投资领域细颗粒度风险事件抽取数据集

数据分布：描述了15个行业、4000家A股上市公司、59个风险事件

认识知识图谱

◆ 什么是知识图谱：金融知识图谱数据

**企业投资
数据**



数据：描述投资机构对企业的投资关系

认识知识图谱

◆ 什么是知识图谱：金融知识图谱数据

```
{ '@id': '0',  
  '@type': 'investor',  
  'name': '瑞华林投资',  
  'relationship': { 'investCompany': [{ '@id': '5617',  
    '@type': 'company',  
    'round': '新三板定增',  
    'date': '2016-03-04' } ] } }
```

投资关系

```
{ '@id': '5322',  
  '@type': 'company',  
  'name': '广州博懿纵横网络科技有限公司',  
  'alterNames': [ '博懿纵横网络',  
    '广州博懿纵横网络',  
    '博懿纵横网络公司',  
    '博懿纵横网络科技',  
    '广州市博懿纵横网络',  
    '博懿纵横网络科技公司',  
    '广州博懿纵横网络公司',  
    '广州博懿纵横网络科技',  
    '广州市博懿纵横网络公司',  
    '广州市博懿纵横网络科技',  
    '广州博懿纵横网络科技公司',  
    '广州市博懿纵横网络科技公司',  
    '广州市博懿纵横网络科技公司' ],  
  'establishDate': '2013-07-30',  
  'address': '广州高新技术产业开发区科学大道231、233号裙楼B1B2栋一层、二层、三层、四层',  
  'relationship': { 'applyPatent': [ ] } }
```

企业信息

如何存储和操作知识图谱

- ◆ 常用图数据：neo4j和nebulagraph



Neo4j是一个高性能的NoSQL图形数据库，支持Cypher查询语言，适合于处理复杂的关系数据



擅长处理千亿节点
万亿条边的超大数据集，同时保持毫秒级查询延时的图数据库解决方案

如何存储和操作知识图谱

◆ 常用图数据：neo4j和nebulagraph

能力	Nebula Graph	Neo4j
数据模型	基于图数据模型，使用节点、边和属性表示实体及其关系	基于图数据模型，使用节点、关系和属性表示数据
分布式能力	从一开始就设计为分布式系统，可以水平扩展以应对大数据量和高并发访问	最初不是分布式设计，但支持集群模式以实现水平扩展

如何存储和操作知识图谱

◆ 常用图数据：neo4j和nebulagraph

能力	Nebula Graph	Neo4j
事务支持	支持事务处理，保证数据一致性和可靠性	支持完整的ACID规则，保证数据可靠性和一致性
查询语言	使用GQL（Graph Query Language），过程式语言，适用于复杂图查询	使用Cypher查询语言，声明式语言，易于学习且功能丰富

如何存储和操作知识图谱

◆ 常用图数据：neo4j和nebulagraph



在小规模数据集上通常表现出色，提供了丰富的图形界面工具和查询语言，便于数据的可视化和查询。Cypher更易于编写复杂的查询



NebulaGraph



适用于处理大规模数据集和高并发访问的场景，特别是在导入效率和特定类型的图查询方面表现出色；

如何存储和操作知识图谱

◆ neo4j使用-安装

安装依赖



Neo4j底层是java, 需要依赖JDK
(OpenJDK / oracle JDK)

下载neo4j



社区版本 neo4j 5.23, 解压


启动服务



neo4j start / neo4j stop /
<http://localhost:7474>

如何存储和操作知识图谱

◆ neo4j使用-可视化界面



执行
cypher命令

如何存储和操作知识图谱

◆ neo4j使用-cypher查询语法

创建节点: (n: label {property1:value1, property2:value2})

```
1 CREATE (p:Person {name: 'Alice'})
2 CREATE (m:Movie {title: 'The Matrix'})
3
4 CREATE (p)-[:LIKES {since: 2022, rating: 5}]->(m)
```

箭头表示关系的方向

创建关系: -[:label {property1:value1, property2:value2}]->

如何存储和操作知识图谱

◆ neo4j使用-cypher查询语法

创建约束：Movie的title必须是唯一，重复创建Moive会报错

1 CREATE CONSTRAINT FOR (n:Movie) REQUIRE (n.title) IS UNIQUE

2

3 CREATE INDEX FOR (m:Movie) ON (m.released)

创建索引：节点的某个属性添加索引

如何存储和操作知识图谱

◆ neo4j使用-cypher查询语法

查询name是Tom Hanks的Person节点，并把这个节点返回

```
MATCH (tom:Person {name: "Tom Hanks"}) RETURN tom
```

```
MATCH (nineties:Movie) WHERE nineties.released ≥ 1990 AND nineties.released < 2000 RETURN nineties.title
```

根据属性条件查询

如何存储和操作知识图谱

◆ neo4j使用-cypher查询语法

查询name是Tom
Hanks的 ACTED_IN
的所有电影

```
1 MATCH (tom:Person {name: "Tom Hanks"})-[:ACTED_IN]→(tomHanksMovies) RETURN tom,tomHanksMovies
```

2

3

```
4 MATCH (tom:Person {name:"Tom Hanks"})-[:ACTED_IN]→(m)←[:ACTED_IN]-(coActors) RETURN DISTINCT  
coActors.name
```

5

6

和tom Hanks共同参演过电影的演员名称

7

```
8 MATCH (people:Person)-[relatedTo]-(:Movie {title: "Cloud Atlas"}) RETURN people.name,  
Type(relatedTo), relatedTo.roles
```

和Cloud Atlas有关系的所有人，返回什么关系

如何存储和操作知识图谱


◆ neo4j使用-cypher查询语法

2个跳连接以所有节点

```
1 MATCH (bacon:Person {name:"Kevin Bacon"})-[*1..2]-(hollywood)
2 RETURN DISTINCT hollywood,bacon
```

如何存储和操作知识图谱

◆ neo4j使用-cypher查询语法



如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

知识的表达

RAG：采用平面文档结构来表示知识

Graph RAG：使用图结构来表示知识，这种结构能更自然地表示层级和非层级关系，更贴近现实世界的知识组织方式

如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

检索机制

RAG: 主要依赖向量相似度搜索来检索信息

Graph RAG: 采用图遍历算法进行信息检索，能够捕捉和利用信息片段之间的复杂关系，提供更丰富、更具语境的信息检索结果

如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

上下文理解
能力

RAG: 在理解复杂的多步骤关系方面存在局限

Graph RAG: 能够捕捉更复杂的多步骤关系，这些关系在RAG中可能被忽略

如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

推理能力

RAG: 推理能力相对有限

Graph RAG: 图结构支持对相互关联信息进行更深入、更复杂的推理

如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

Graph RAG

多跳关系查询：在xxx的同学的朋友中，谁在阿里巴巴工作？

语义关联查询：哪些公司提供LLM产品，并且已经取得国家认证许可？

知识推理查询：根据患者的症状和病史，推断可能的疾病并提供治疗方案

涉及聚合统计查询：过去两年中大模型增加了多少，哪些公司占主导地位？


时序关联查询：查询过去10年的xxx公司的投资与并购事件？

如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

GraphRAG: 还有哪些采用超感光摄影的手机？

RAG: 如果没有明显的文本块匹配这里的问题，就需要依赖程序对此进行查询分解与规划




如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

GraphRAG:有哪些适合拍摄高质量视频的智能手机，并且具有良好的用户口碑？

RAG: 通过如“智能手机”、“高质量视频”、“良好口碑”等关键词检索近似文本块；如果存储的文本块中没有同时提到这些关键词的近似信息，系统可能会返回一些仅仅与部分关键词相关的内容，



如何构建Graph RAG

◆ RAG和Graph RAG有什么区别？

GraphRAG:最近几年高端智能手机的整体发展趋势是怎样的？

RAG: 可能会检索到包含“高端智能手机”、“发展”或“最近几年”等关键词的文本块，但难以将这些块串联起来，形成一个连贯的趋势叙事。会导致结果往往是片段化的信息，难以全面地回答查询



如何构建Graph RAG

◆ 构建Graph RAG的过程

提取问题中的关键词信息



根据关键词信息检索图数据库



拼接检索得到信息作为上下文，送到大语言模型来生成答案

如何构建Graph RAG

◆ 构建Graph RAG的过程

总结下哪些公司
进行了企业转型



总结、公司、企业转型



检索图数据库

```
MATCH (i:Investor)-[:INVEST]→(c:Company)-[r:HAPPEN]→(e)
WHERE 1=1 and e.name = "企业转型"
RETURN i.name as investor, c.name as company_name, e.name as even_type, r as relation
```



LLM

如何构建Graph RAG

◆ 构建Graph RAG的过程-提取关键词

提取关键词
prompt

给定一些初始查询，提取最多 `{max_keywords}` 个相关关键词，考虑大小写、复数形式、常见表达等。
用 `'^'` 符号分隔所有同义词/关键词： `'关键词1^关键词2^ ... '`

注意，结果应为一行，用 `'^'` 符号分隔。

查询： `{query_str}`

关键词：

如何构建Graph RAG

◆ 构建Graph RAG的过程-从文本中构建三元组

下面提供了一些文本。根据文本，提取最多 `{max_knowledge_triplets}` 个知识三元组，形式为（实体,关系,实体或属性）。避免使用停用词。仅输出三元组，不要有多余解释和说明。

示例：

文本：麦迪是姚明的队友。

三元组：麦迪, 队友, 姚明

文本：阿里巴巴是马云在1999年创立的公司

三元组：

阿里巴巴, 是, 公司

阿里巴巴, 创立于, 马云

阿里巴巴, 创立于, 1999年

文本：{text}

三元组：█

总结和展望

◆ 总结

Graph RAG

三元组：通过三元组<主体，谓语，客体>了解什么是知识图谱，并了解知识图谱的应用场景

图形化关系结构：可以表达更丰富的关系语义信息，支持深入的逻辑推理

Nebulagraph和neo4j：常用的图数据库

总结和展望

◆ 总结

Graph RAG

neo4j：安装部署、通过cypher去使用neo4j

RAG和Graph RAG区别：Graph RAG可以很好的支持众多关联查询（多跳关系，语义关联，知识推理等）

给出了构建Graph RAG的过程

总结和展望

◆ 展望：如何自我学习，跟进前沿技术

AI技术



发展太快了



终生学习

总结和展望

◆ 展望：如何自我学习，跟进前沿技术

入门一个全新领域

找到领域的关键词：可以从综述出发找到关键词，去了解关键词的含义，从这些关键词就可以知道领域最重要的是什么

阅读3-5经典的专业书籍或论文：搭建基础的理论知识

跟随领域专家：找到这个领域的专家，阅读他们的观点，分析和复述他们的观点

总结和展望

◆ 展望：如何自我学习，跟进前沿技术

跟进前沿技术

获取技术的渠道：技术公众号，技术媒体号，B站，youtube、paperwithcode等，可以通过这些获取最新技术的报导，对技术发展趋势有一个大概的认识

深入了解：对于你感兴趣的技术，做深入的阅读（论文/代码），由粗到细（借助AI辅助阅读+公开的视频的讲解+自己精读+代码的实现）

定期看综述性文章

总结和展望

◆ 展望：如何自我学习，跟进前沿技术

形成结构化的知识：写专栏，blog和学习笔记，
形成对知识的结构化认识和本质的认识

跟进前沿技术

费曼学习法：说出你的知识